프로젝트 #1 주제발표

딥러닝 기반 논문 리뷰

이은혜
eunhye4611@cbnu.ac.kr
충북대학교 산업인공지능학과

INDUSTRIAL AI RESEARCH CENTER

CONTENTS

I **프로젝트 #1 개요**
프로젝트 개요 및 선정 논문 소개,

II **서론 (Introduction)**
연구 배경, 연구 필요성, 문제 정의

III **방법 (Methodology)**
문제 해결을 위한 방법론

IV **실험 구성 및 평가 방법 (Experiment Settings)**
데이터셋, 하이퍼파라미터, 컴퓨팅 환경, 평가지표

V **결과 및 분석 (Results & Analysis)**
학습 결과, 정확도, 혼동행렬, 비교 평가, 결과 분석

프로젝트 #1 개요

■ 프로젝트 목표

다중 카메라 환경에서 생성형 AI 기반 선제적 갤러리 구축을 통한
실시간 보행자 재식별 정확도 향상 시스템 개발

■ 프로젝트 배경 및 필요성

1) 프로젝트 배경

- 산업시설·공공장소 등에서 CCTV 기반 보안·모니터링 수요가 증가하면서 다수의 카메라를 연계한 보행자 실시간 추적 기술의 중요성이 높아지고 있음
- 생성형 AI를 활용해 Re-ID 성능을 향상시키려는 연구가 진행되고 있으나 기존 연구의 대부분은 학습 단계에서의 데이터 증강에 집중되어 있고, 추론 단계에서 실시간으로 갤러리를 선제 구축하는 접근은 아직 충분히 탐색되지 않았음

2) 프로젝트 필요성

- 기술적 측면: 기존 Re-ID 방법은 보행자가 카메라에 실제로 등장한 이후에야 매칭을 시도하여 실시간 처리가 어려움. 본 연구는 A카메라 등장 즉시 생성형 AI로 B, C, D 시점 이미지를 실시간으로 선제 생성해 갤러리에 미리 등록하는 방식으로 이 문제를 접근함
- 산업적 측면: 철도·공항·쇼핑몰 등 실무 CCTV 환경에서는 카메라 간 시점 불일치로 인한 매칭 오류가 빈번하게 발생함. 본 연구의 방법은 기존 Re-ID 모델의 재학습 없이 추론 단계에서 적용 가능한 구조로 설계됨
- 사회적 측면: 범죄 용의자 추적, 실종자 수색 등 다중 카메라 환경에서 실시간 동일 인물 식별이 요구되는 공공 안전 분야에서 활용 가능성이 있음

프로젝트 #1 개요

INDUSTRIAL AI RESEARCH CENTER

■ 선정 논문

논문 제목	Learning Generalisable Omni-Scale Representations for Person Re-Identification
출판사/저널	IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI)
IF/JCR	IF: 18.6 / JCR Q1
인용횟수	446회 (Google Scholar 기준, 2026년 4월)

Learning Generalisable Omni-Scale Representations for Person Re-Identification

Kaiyang Zhou, Yongxin Yang, Andrea Cavallaro, and Tao Xiang

Abstract—An effective person re-identification (re-ID) model should learn feature representations that are both discriminative, for distinguishing similar-looking people, and generalisable, for deployment across datasets without any adaptation. In this paper, we develop novel CNN architectures to address both challenges. First, we present a re-ID CNN termed omni-scale network (OSNet) to learn features that not only capture different spatial scales but also encapsulate a synergistic combination of multiple scales, namely omni-scale features. The basic building block consists of multiple convolutional streams, each detecting features at a certain scale. For omni-scale feature learning, a unified aggregation gate is introduced to dynamically fuse multi-scale features with channel-wise weights. OSNet is lightweight as its building blocks comprise factorised convolutions. Second, to improve generalisable feature learning, we introduce instance normalisation (IN) layers into OSNet to cope with cross-dataset discrepancies. Further, to determine the optimal placements of these IN layers in the architecture, we formulate an efficient differentiable architecture search algorithm. Extensive experiments show that, in the conventional same-dataset setting, OSNet achieves state-of-the-art performance, despite being much smaller than existing re-ID models. In the more challenging yet practical cross-dataset setting, OSNet beats most recent unsupervised domain adaptation methods without using any target data. Our code and models are released at `https://github.com/KaiyangZhou/deep-person-reid`.

Index Terms—Person Re-Identification; Omni-Scale Learning; Lightweight Network; Cross-Domain Re-ID; Neural Architecture Search

서론 (Introduction)

구분	내용
연구배경	• CCTV 기반 보안 수요 증가로 다중 카메라 환경에서 동일 인물을 자동으로 찾는 Re-ID 기술이 주목받고 있다. • 딥러닝 발전으로 CNN 기반 Re-ID 성능이 크게 향상되었으나 실제 대규모 배포를 위해서는 여전히 해결되지 않은 문제들이 존재한다.
문제 정의	• 기존 CNN 기반 Re-ID 모델은 두 가지 핵심 한계를 가진다. • ① 식별력 한계 → 단일 스케일 특징만 추출하여 신발·로고 같은 세부 특징과 전체 체형 같은 전역 특징을 동시에 포착하지 못함 • ② 일반화 한계 → 학습 데이터셋과 다른 새로운 카메라 환경에 적용 시 성능이 크게 저하됨. 기존 도메인 적응 방법들은 타겟 도메인 데이터 수집과 재학습이 반드시 필요함
연구 필요성	• 타겟 데이터, 재학습 없이도 다양한 스케일의 특징을 동시에 학습하는 경량 Re-ID 모델이 필요하다.

■ OSNet – 옴니스케일 특징학습, 같은 도메인에서의 식별력 향상

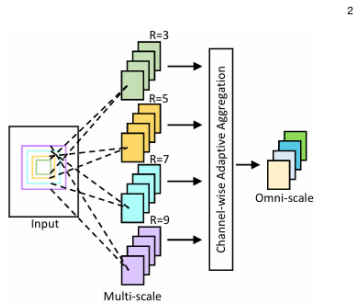

Fig. 2. A schematic of OSNet building block. R: Receptive field size.

OSNet 빌딩 블록 개요도

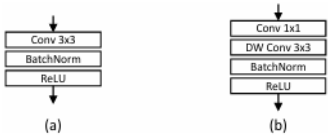

Fig. 3. (a) Standard and (b) Lite 3×3 convolution. DW: Depth-Wise.

표준 Conv vs Lite 3×3 비교

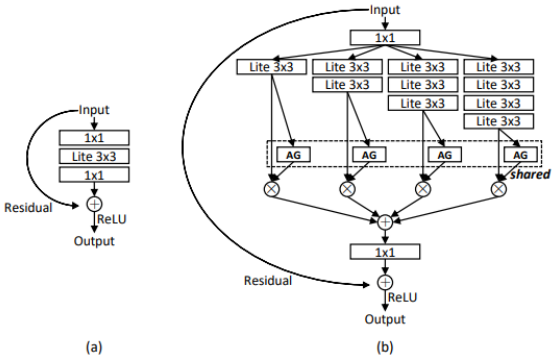

Fig. 4. (a) Baseline bottleneck. (b) OSNet bottleneck. AG: Aggregation Gate. The first/last 1×1 layers used to reduce/restore feature dimension.

Baseline vs OSNet bottleneck 비교

기존 CNN은 하나의 필터 크기로만 특징을 추출하여 세부 특징(로고, 신발)과 전체 특징(체형, 자세)을 동시에 포착하지 못하는 한계가 있음
이를 해결하기 위해 OSNet은 다음 구조를 제안함

- 하나의 블록 안에 수용 필드 크기가 다른 4개 스트림(R=3, 5, 7, 9)을 동시에 운용
- 각 스트림은 서로 다른 범위의 특징을 추출
- Aggregation Gate(AG)가 입력 이미지에 따라 어떤 스케일이 중요한지 동적으로 판단하여 채널 단위로 가중치를 부여해 합침
- 이를 통해 세부 특징과 전체 특징을 동시에 포착하는 옴니스케일 특징 생성

또한 표준 Convolution을 Pointwise + Depthwise로 분해하는 Lite 3×3 구조를 도입하여 계산량을 약 8배 줄임으로써, 파라미터 수 2.2M을 유지하며 성능을 높이는 방법을 제안

방법 (Methodology)

■ OSNet-AIN – Instance Normalisation + NAS를 통한 일반화

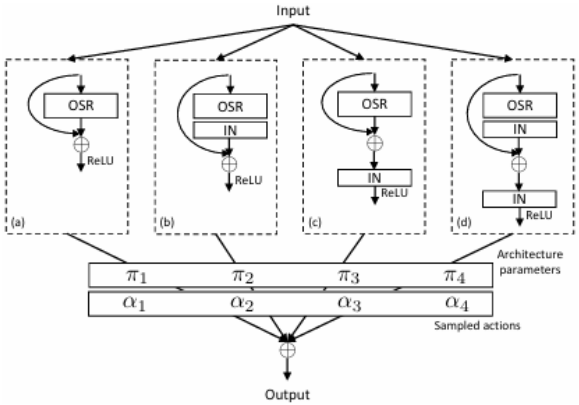

NAS 탐색 공간 (4가지 후보 구조 비교 그림)

TABLE 7
Ablation study for instance normalisation and architecture search.

Method	Market1501→Duke				Duke→Market1501			
	R1	R5	R10	mAP	R1	R5	R10	mAP
IBN-Net [19]	43.7	59.1	65.2	24.3	50.7	69.1	76.3	23.5
OSNet	44.7	59.6	65.4	25.9	52.2	67.5	74.7	24.0
OSNet-IBN	47.9	62.7	68.2	27.6	57.8	74.0	79.5	27.4
OSNet-AIN	**52.4**	**66.1**	**71.2**	**30.5**	**61.0**	**77.0**	**82.5**	**30.6**

IN 효과 비교표
(OSNet vs OSNet-IBN vs OSNet-AIN 수치 비교)

학습한 데이터셋과 다른 카메라 환경에 적용하면 밝기·색온도·시점 차이로 인해 성능이 크게 저하되는 도메인 갭 문제가 발생함
이를 해결하기 위해 OSNet-AIN은 다음 구조를 제안함

- Instance Normalisation(IN) 을 OSNet에 삽입하여 이미지마다 각자의 평균/분산으로 정규화함으로써 카메라 스타일 차이를 제거
- Batch Norm이 미니배치 전체를 기준으로 정규화하는 것과 달리, IN은 이미지 한 장씩 독립적으로 정규화하여 카메라 특성에 무관한 특징만 남김
- IN 레이어를 어느 위치에 삽입할지 NAS(Neural Architecture Search) 로 자동 탐색하여 4096가지 조합 중 최적 구조를 선택

실험 구성 및 평가 방법 (Experiment Settings)

■ 실험 구성 / 평가 지표

1. 데이터셋

TABLE 2
Statistics of person re-ID datasets.

Dataset	# IDs	# images	# cameras
Market1501 [81]	1,501	32,668	6
CUHK03 [3]	1,467	28,192	2
Duke [82], [83]	1,812	36,411	8
MSMT17 [84]	4,101	126,411	15
VIPeR [85]	632	1,264	2
GRID [86]	251	1,275	6
CUHK01 [87]	971	3,882	2

2. 학습 설정

입력크기 256*128 Batch:64	옵티마이저 SGD(scratch) AMSGrad(fine-tune)	학습에폭 350(scratch) 250(fine-tune)

데이터 증강
Random Filp / Random Crop / Random Patch / Random Erasing

3. 평가지표

Rank-1 갤러리 1위 결과가 정답일 확률	mAP 전체 정답 순위 종합 점수

결과 및 분석 (Results & Analysis)

INDUSTRIAL AI RESEARCH CENTER

■ OSNet의 대형 데이터셋 실험 결과

TABLE 3
Results on big re-ID datasets. It is noteworthy that OSNet surpasses most published methods by a clear margin on all datasets with only 2.
million parameters, far less than the best-performing ResNet-based methods. -: not reported. †: reproduced by us.

Method	Venue	Backbone	Params (M)	Market1501		CUHK03		Duke		MSMT17	
				R1	mAP	R1	mAP	R1	mAP	R1	mAP
Trained from scratch											
MobileNetV2† [12]	CVPR'18	MobileNetV2	2.2	87.0	69.5	46.5	46.0	75.2	55.8	50.9	27.0
BraidNet [89]	CVPR'18	BraidNet	-	83.7	69.5	-	-	76.4	59.5	-	-
HAN [5]	CVPR'18	Inception	4.5	91.2	75.7	41.7	38.6	80.5	63.8	-	-
Auto-ReID [90]	ICCV'19	Auto	13.1	90.7	74.6	-	-	-	-	-	-
OSNet (*ours*)	This work	OSNet	2.2	**93.6**	**81.0**	**57.1**	**54.2**	**84.7**	**68.6**	**71.0**	**43.3**
Pre-trained on ImageNet											
SVDNet [91]	ICCV'17	ResNet	>23.5	82.3	62.1	41.5	37.3	76.7	56.8	-	-
PDC [35]	ICCV'17	Inception	>6.8	84.1	63.4	-	-	-	-	58.0	29.7
HAP2S [92]	ECCV'18	ResNet	>23.5	84.6	69.4	-	-	75.9	60.6	-	-
DPFL [46]	ICCVW'17	Inception	>6.8	88.6	72.6	40.7	37.0	79.2	60.6	-	-
DaRe [45]	CVPR'18	DenseNet	>23.5	89.0	76.0	63.3	59.0	80.2	64.5	-	-
PNGAN [93]	ECCV'18	ResNet	>23.5	89.4	72.6	-	-	73.6	53.2	-	-
GLAD [29]	ACM MM'17	Inception	>6.8	89.9	73.9	-	-	-	-	61.4	34.0
KPM [31]	CVPR'18	ResNet	>23.5	90.1	75.3	-	-	80.3	63.2	-	-
MLFN [6]	CVPR'18	ResNeXt	32.5	90.0	74.3	52.8	47.8	81.0	62.8	-	-
FDGAN [94]	NeurIPS'18	ResNet	>23.5	90.5	77.7	-	-	80.0	64.5	-	-
DuATM [24]	CVPR'18	DenseNet	>7.0	91.4	76.6	-	-	81.8	64.6	-	-
Bilinear [37]	ECCV'18	Inception	>6.8	91.7	79.6	-	-	84.4	69.3	-	-
G2G [95]	CVPR'18	ResNet	>23.5	92.7	82.5	-	-	80.7	66.4	-	-
DeepCRF [96]	CVPR'18	ResNet	26.1	93.5	81.6	-	-	84.9	69.5	-	-
PCB [23]	ECCV'18	ResNet	27.2	93.8	81.6	63.7	57.5	83.3	69.2	68.2	40.4
SGGNN [97]	ECCV'18	ResNet	>23.5	92.3	82.8	-	-	81.1	68.2	-	-
Mancs [98]	ECCV'18	ResNet	>25.1	93.1	82.3	65.5	60.5	84.9	71.8	-	-
AANet [99]	CVPR'19	ResNet	>23.5	93.9	83.4	-	-	87.7	74.3	-	-
CAMA [100]	CVPR'19	ResNet	>23.5	94.7	84.5	66.6	64.2	85.8	72.9	-	-
IANet [25]	CVPR'19	ResNet	>23.5	94.4	83.1	-	-	87.1	73.4	75.5	46.8
DGNet [101]	CVPR'19	ResNet	>23.5	**94.8**	86.0	65.6	61.1	86.6	74.8	77.2	52.3
Auto-ReID [90]	ICCV'19	Auto	13.1	94.5	85.1	**73.3**	**69.3**	-	-	78.2	52.5
OSNet (*ours*)	This work	OSNet	2.2	**94.8**	**86.7**	72.3	67.8	**88.7**	**76.6**	**79.1**	**55.1**

1. 파라미터 대비 성능
-2.2m 파라미터로 ResNet 기반 모델들과 동등하거나 더 높은 성능

2. Trained from scratch 그룹
- 같은 파라미터인 MobileNetV2(87.0%)보다 OSNet(93.6%)이 더 높음

3. Pre-trained on ImageNet 그룹
- Market-1501 기준 Rank-1 94.8%, mAP 86.7%
- 동등한 DGNet보다 파라미터가 적음

기존 ResNet 기반 모델 대비 1/10 수준의 파라미터로 동등 이상의 성능을 달성

■ OSNet-AIN

TABLE 7
Ablation study for instance normalisation and architecture search.

Method	Market1501→Duke				Duke→Market1501			
	R1	R5	R10	mAP	R1	R5	R10	mAP
IBN-Net [19]	43.7	59.1	65.2	24.3	50.7	69.1	76.3	23.5
OSNet	44.7	59.6	65.4	25.9	52.2	67.5	74.7	24.0
OSNet-IBN	47.9	62.7	68.2	27.6	57.8	74.0	79.5	27.4
OSNet-AIN	**52.4**	**66.1**	**71.2**	**30.5**	**61.0**	**77.0**	**82.5**	**30.6**

1. IN 추가 효과
OSNet (IN 없음): Market→Duke R1 44.7%
OSNet-AIN: Market→Duke R1 52.4%

2. 수동 설계 vs 자동 탐색
OSNet-IBN (수동): Market→Duke R1 47.9%
OSNet-AIN (NAS): Market→Duke R1 52.4%

3. IBN-Net과 비교
IBN-Net (ResNet 기반 IN 적용): 43.7%
OSNet-AIN: 52.4%

IN 레이어를 NAS로 자동 탐색한 OSNet-AIN이 수동 설계보다 일관되게 높은 성능을 보여
자동 구조 탐색의 필요성을 입증

참고 문헌

[1] Zhou, K., Yang, Y., Cavallaro, A., & Xiang, T. (2022). Learning Generalisable Omni-Scale Representations for Person Re-Identification. IEEE Transactions on Pattern Analysis and Machine Intelligence, 44(9), 5056–5069.

[2] He, S., Luo, H., Wang, P., Wang, F., Li, H., & Jiang, W. (2021). TransReID: Transformer-Based Object Re-Identification. ICCV 2021.

[3] Zheng, L., Shen, L., Tian, L., Wang, S., Wang, J., & Tian, Q. (2015). Scalable Person Re-identification: A Benchmark. ICCV 2015. (Market-1501 데이터셋)

[4] Pan, X., Luo, P., Shi, J., & Tang, X. (2018). Two at Once: Enhancing Learning and Generalization Capacities via IBN-Net. ECCV 2018. (IN 관련)

감사합니다

Q&A